

涉密论文 ☐ 公开论文 ☒

浙江大学

本科生毕业论文(设计)



题目 基于加权损失函数的天文图像超分辨率方法研究

姓名与学号 李平川 3210104672

指导教师 刘平

年级与专业 2021 级信息与计算科学

所在学院 数学科学学院

提交日期 2025 年 5 月

浙江大学本科生毕业论文（设计）承诺书

1. 本人郑重地承诺所呈交的毕业论文（设计），是在指导教师的指导下严格按照学校和学院有关规定完成的。

2. 本人在毕业论文（设计）中除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 浙江大学 或其他教育机构的学位或证书而使用过的材料。

3. 与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

4. 本人承诺在毕业论文（设计）工作过程中没有伪造数据等行为。

5. 若在本毕业论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

6. 本人完全了解 浙江大学 有权保留并向有关部门或机构送交本论文（设计）的复印件和磁盘，允许本论文（设计）被查阅和借阅。本人授权 浙江大学 可以将本论文（设计）的全部内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编本论文（设计）。

作者签名：

签字日期： 年 月 日

导师签名：

签字日期： 年 月

致谢

首先，我衷心感谢我的导师刘平老师在整个毕业论文写作过程中给予我的悉心指导与无私帮助。刘老师严谨的治学态度、渊博的专业知识以及耐心细致的指导让我受益匪浅。在论文选题、研究方法、写作思路等方面，刘老师都给予了我宝贵的建议，使我能够顺利完成本次课题研究。

同时，我也感谢在本科学习期间给予我帮助和鼓励的各位老师和同学。你们的支持是我不断前进的重要动力。

最后，感谢家人对我始终如一的理解与支持，是你们给予了我坚强的后盾，让我能够无后顾之忧地专注于学业和研究。

本文相关的所有实验代码已开源，详见：

<https://github.com/CheeseLee888/AstronomyImageSR.git>

摘要

人类对于浩瀚星空的探索从未停止。地面天文望远镜在捕获天文图像时，由于大气扰动、望远镜内部成像缺陷等因素，所得到的图像往往分辨率较低，伴有模糊和噪声。为了更好地展开天文研究，清晰的天文图像是极其必要的。除了在成像阶段想办法提升图像质量，我们还可以借助深度学习技术，对已经得到的低分辨率图像进行超分辨率计算，试图将其恢复到与高分辨率图像相接近的结果。本文针对 SRCNN 网络中的损失函数展开研究。天文图像的特点是，细节基本集中在中心区域，而背景一般都是无意义的黑色。为了使超分辨率实现的天文图像更关注细节区域，我们将损失函数设计为加权的，使得中心细节区域具有更高的权重，让深度学习网络在训练过程中更加注重对中心细节区域的恢复。本文探讨了加权损失函数对提升图像恢复质量带来的效果，并研究了如何设置加权损失函数的参数。

关键字：天文成像，图像优化，去卷积算法，深度学习算法，超分辨网络，加权损失函数

Abstract

Human exploration of the vast universe has never ceased. However, when capturing astronomical images with ground-based telescopes, atmospheric turbulence and internal imperfections of the lens system often result in low-resolution images accompanied by blur and noise. To better support further astronomical research, obtaining high-quality, clear astronomical images is essential. In addition to enhancing image quality during the acquisition phase, deep learning techniques can also be employed to improve resolution through post-processing. This study focuses on modifying the loss function design of the SRCNN network for astronomical image super-resolution. Astronomical images are characterized by fine structures typically concentrated in the center, while the background usually consists of irrelevant dark regions. To enable the super-resolution network to focus more on these central fine structures, we propose using a weighted loss function that increases the importance of central details during training. This encourages the network to prioritize detail recovery in key regions. This work explores the effect of using a weighted loss function on image quality improvement and investigates how to set the corresponding weighting parameter.

Key words: Astronomical imaging, image enhancement, deconvolution algorithm, deep learning algorithm, super-resolution network, weighted loss function

目录

1	引言	7
2	准备工作	8
2.1	图像比较方法	8
2.2	数据集	9
2.3	Richard-Lucy 方法简介	10
2.4	超分辨率卷积神经网络 (SRCNN) 简介	11
3	核心研究	13
3.1	使用 Richard-Lucy 方法对图像进行 SR	13
3.2	使用 SRCNN 方法对图像进行 SR	14
3.2.1	MSE 准则	14
3.2.2	加权 MSE 准则	15
3.2.3	MAE 准则	16
3.2.4	加权 MAE 准则	17
3.2.5	更大的加权幅度	17
3.2.6	总结	18
4	结论	19

1 引言

试图将低分辨率图像 (LR Image) 复原成高分辨率图像 (HR Image), 这一操作称为超分辨率 (Super Resolution, SR)。由于天文图像在成像过程中会经过卷积而降低质量, 因此超分辨率这一操作也可被称为去卷积。

目前已经有许多成熟运用的经典去卷积算法, 比如 Richardson-Lucy 算法、维纳滤波 (Wiener Filter) 法、最大熵法、Tikhonov 正则化等。然而, 以上经典去卷积算法都需要依赖点扩散函数 (Point Spread Function, PSF)。PSF 描述了一个成像系统对单一点光源的响应。理想情况下, 点源应在图像中表现为一个像素点, 但由于光学系统的衍射、仪器误差以及观测环境的影响, 点源会在成像中呈现为一个扩散的斑点, 形成所谓的 PSF。在天文成像中, PSF 主要由光学系统和大气湍流共同决定。光学系统相对稳定, 其对 PSF 的影响可通过光学模型精确计算; 然而, 大气湍流复杂且灵活多变, 其对 PSF 的影响难以准确估计。因此, 空间望远镜相较于地面望远镜, 避免了大气湍流的影响, 更容易得到精确的 PSF。无论怎样, 经典去卷积算法由于依赖 PSF 都有一定的局限性。

近几年来, 深度学习技术快速发展, 对各行各业产生了颠覆性的影响。天文成像的去卷积也可以借助这一“东风”。由于深度学习模型无需事先估计 PSF, 另辟蹊径, 有可能从根本上摆脱现有的困境, 大大提升成像精确度。根据训练过程中是否依赖成对的低分辨率 (LR) 与高分辨率 (HR) 图像数据, 可以大致分为有监督 SR 模型和无监督 SR 模型。有监督 SR 模型依赖于大规模成对数据, 通过明确的监督信号训练网络, 在恢复高分辨率图像上通常具有较高的精度, 但受限于数据获取和领域匹配问题。无监督 SR 模型则利用未配对数据或图像内部统计进行训练, 具有更好的灵活性和泛化能力, 适用于实际场景中的多样化低分辨率图像, 但训练和恢复过程可能更复杂且效果略有不稳定。

本文大多数内容来源于论文 [4]。本文是要探讨该论文中的一个子问题: 在 SRCNN 模型中, 能否调整损失函数, 使得网络更有选择性地针对细节区域。

本文通过设计加权损失函数, 给予中心细节区域更高的权重, 使得深度学习网络将主要注意力转移到图像的细节区域, 增强细节的恢复; 同时降低背景区域的权重, 使网络仍能在这些区域进行训练, 并减轻这些区域存在的任何噪音或模糊。

2 准备工作

2.1 图像比较方法

峰值信噪比 (PSNR) 峰值信噪比 (Peak Signal-to-Noise Ratio, PSNR) 是一种直接且直观的图像比较方法。如果最大像素值记为 L ，真实图像 A 具有 N 个像素，重建图像为 B ，则 A 和 B 之间的 PSNR 定义如下：

$$PSNR = 10 \times \log_{10} \left(\frac{L^2}{\frac{1}{N} \sum_{n=1}^N (A(n) - B(n))^2} \right). \quad (1)$$

从公式的分母可以看出，PSNR 与均方误差 (MSE) 相关，因此它通过像素间的差异来评估图像质量，而不是视觉感知。

结构相似性指数 (SSIM) 在图像处理领域，结构相似性指数 (Structural Similarity, SSIM)[5] 是最常用的图像比较方法之一。该指数基于图像的结构、亮度和对比度，是一种衡量图像感知质量的度量方法。

对于两幅图像 A 和 B ，SSIM 指数计算 11×11 像素块 x 和 y 的相似性，并定义如下：

$$SSIM(x, y) = (l(x, y))^\alpha (c(x, y))^\beta (s(x, y))^\gamma. \quad (2)$$

其中，常数 α 、 β 和 γ 均大于零，并通常设定为 1 以简化计算。

亮度分量

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1}, \quad (3)$$

其中， μ_x 和 μ_y 分别是块 x 和 y 的均值，可通过

$$\mu_x = \frac{1}{N} \sum_{i=1}^N x_i \quad (4)$$

估计。 C_1 是一个用于避免除零问题的常数，通常设定为 $(K_1 L)^2$ ，其中 L 是像素的动态范围， $K_1 \ll 1$ 。

对比度分量

$$c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2}. \quad (5)$$

其中， $C_2 = (K_2 L)^2$ ， $K_2 \ll 1$ ， σ_x 和 σ_y 分别表示信号的对比度估计，其计算公式如下：

$$\sigma_x = \left(\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu_x)^2 \right)^{\frac{1}{2}}. \quad (6)$$

结构分量

$$s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x \sigma_y + C_3}. \quad (7)$$

其中，共方差 σ_{xy} 由以下公式计算：

$$\sigma_{xy} = \frac{1}{N-1} \sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y), \quad (8)$$

且 C_3 设定为 $C_3 = C_2/2$ 。

选择性结构相似性指数 (SSSIM) 选择性结构相似性指数 (Selective SSIM, SSSIM) 是针对天文图像进行优化的 SSIM 方法。天文图像的细节基本集中在中心区域，占整幅图像的一小部分，而背景一般都是无意义的黑色。SSIM 的设计是对整幅图像的，不适用于检测细节区域内的差异。而 SSSIM 方法先利用聚类方法将图像的细节区域和背景区域分离开来，然后针对细节区域进行相似性评估。

总结 为了更好地比较不同图像之间的相似性评分，本文采用 SSIM 和 SSSIM 方法，这是因为这两种方法的评分取值范围限定在 $[0, 1]$ 。而 PSNR 方法的评分取值没有上限。在 SSIM 和 SSSIM 方法之间，本文着重于对 SSSIM 分数的评价，因为它更加注重细节区域内的评估，更适用于天文图像的特点。

2.2 数据集

本文采用的天文图像数据集是 COSMOS NICMOS 数据集, 地址为: <https://irsa.ipac.caltech.edu/data/COSMOS/images/nicmos/>。该数据集的图片格式为 FITS。FITS (Flexible Image Transport System) 格式是天文学中广泛使用的图像存储标准。COSMOS NICMOS 数据集来源于哈勃太空望远镜 (Hubble Space Telescope, HST) 上的 NICMOS (近红外摄影仪)，使用的是 NIC3 相机，是 COSMOS (Cosmic Evolution Survey, 宇宙演化调查) 项目的一部分。共有 474 张图像，大小均为 1.2M。

本文采用有监督的训练方法，上面取得的图像作为高分辨率图像 (HR Image)，然后引入一些降低图像质量的因素模拟出低分辨率图像 (LR Image)。我们主要采用的降质方法为：1. 引入高斯模糊卷积，核标准差为 *stddev*；2. 引入均值为 0，标准差为 2 的高斯噪声，幅度为 *gaussian_scale*；3. 引入 $\lambda = 1$ 的泊松噪声，幅度为 *poisson_scale*。其中，高斯卷积核可视为简化的 PSF，用于模拟不同仪器或观测条件下图像的模糊程度。

本文设置了三个不同的低分辨率图像数据集，参数情况如下：

数据集 4.001 $stddev = 4, gaussian_scale = 0.01, poisson_scale = 0.01;$

数据集 10.001 $stddev = 10, gaussian_scale = 0.01, poisson_scale = 0.01;$

数据集 10.0015 $stddev = 10, gaussian_scale = 0.015, poisson_scale = 0.015.$

三个低分辨率图像数据集先进行归一化处理，再裁剪至 $256 * 256$ 像素，随后以对应参数进行高斯模糊并添加高斯噪声和泊松噪声。为了更有效地分析图像的细节区域，我们使用聚类方法，将图像的细节区域专门框选出来，用于后续的研究，得到所谓的“selective HR and LR images”。具体操作请参考本文所附代码。

	PSNR		SSIM		SSSIM	
	MEAN	SD	MEAN	SD	MEAN	SD
数据集 4.001	37.032	1.530	0.646	0.098	0.574	0.091
数据集 10.001	36.699	1.782	0.638	0.093	0.563	0.084
数据集 10.0015	33.777	1.640	0.445	0.112	0.374	0.099

表 1: 与原始 HR 数据集相比，不同 LR 数据集 PSNR, SSIM 和 SSSIM 分数的平均值 (MEAN) 与标准差 (SD)

表1和图A.2列出了不同 LR 数据集与原始 HR 数据集之间的图像比较结果，可以看出，数据集 4.001 和 10.001 的表现非常相近，说明两者虽然在 PSF 参数上不同，但整体图像的破坏程度较为一致。有三种可能的原因：(1) 天文图像的有效信息集中在中心很小一部分，虽然 SSSIM 能够针对中心这一小块区域进行对比，但高斯模糊的作用是针对整体的，导致实际中心区域的变化程度并不高；(2) 原始 HR 图像可能就存在一定的模糊，而在“模糊”上加“模糊”，可能最终的效果都是“很模糊”而看不出模糊的程度区别；(3) 本文设置的变量是卷积核的标准差 (stddev)，这可能并不是导致 LR 图像产生明显区别的关键因素。另一方面，数据集 10.0015 的结果看起来非常合理，更大的噪声导致整体 SSIM/SSSIM 分数产生明显下降。

2.3 Richard-Lucy 方法简介

Richardson-Lucy 算法属于贝叶斯方法的一种。贝叶斯方法的核心目标是建立条件概率密度的关系：

$$p(O | I) = \frac{p(I | O)p(O)}{p(I)}.$$

当右侧表达式被最大化时，即可得到贝叶斯解 [3]。

Richardson-Lucy 去卷积是一种在天文成像中常用的方法。该方法的优势在于：能保持通量不变，并且始终得到正值解。该算法基于带有泊松噪声的最大似然估计，其概率 $p(I | O)$ 表达为：

$$p(I | O) = \prod_{x,y} \frac{((P * O)(x, y))^{I(x,y)} \exp[-(P * O)(x, y)]}{I(x, y)!}.$$

将对数似然函数对 $I(x, y)$ 求导并令其为 0，有：

$$\frac{d \ln p(I | O)(x, y)}{dI(x, y)} = 0 \quad (3.1)$$

从而最大化概率并得到如下中间结果：

$$\left[\frac{I}{P * O} * P^* \right] (x, y) = 1$$

其中 P^* 表示点扩散函数的翻转，并假设其归一化为 1。最终算法通过两边同时乘以 $O(x, y)$ 并进行 Picard 迭代得到：

$$O^{n+1}(x, y) = \left[\frac{I}{(P * O^n)} * P^* \right] (x, y) O^n(x, y).$$

2.4 超分辨率卷积神经网络 (SRCNN) 简介

超分辨率卷积神经网络 (SRCNN) 是一种由 Dong 等人于 2015 年 [1] 提出的单幅图像超分辨率 (SR) 深度学习方法。该方法采用了一个三层的全卷积神经网络，具有前馈式结构，因此在计算上高效，同时还能取得准确的重建效果。SRCNN 受启发于基于实例的方法，例如稀疏编码方法，在此类方法中，通过学习过完备字典来表示低分辨率 (LR) 与高分辨率 (HR) 图像块之间的关系。SRCNN 通过网络层隐式学习 HR 与 LR 图像的特征，从而建立两者特征之间的映射关系。

该网络的三层结构可以描述如下：

特征块提取与表示层 (Feature patch extraction and representation layer) 从 LR 图像中提取图像块，将其表示为高维向量。所有向量组成特征图集合。这些向量的维度与特征图数量对应，因此对于每个图像块，提取出一个 n_1 维的特征。该层可以通过如下操作表示：

$$F_1(Y) = \max(0, W_1 * Y + B_1),$$

其中 Y 表示 LR 图像， W_1 表示卷积核， B_1 表示偏置项， $*$ 表示卷积操作。 W_1 由 n_1 个卷积核组成，每个卷积核的尺寸为 $c \times f_1 \times f_1$ ，其中 c 是输入图像的通道数， f_1 是卷积核的空间尺寸。在简单情况下， W_1 在整张图像上进行 n_1 次卷积操作，每次卷积使用 $c \times f_1 \times f_1$ 大小的卷积核，输出 n_1 张特征图。 B_1 是 n_1 维的偏置向量，每一维对应一个卷积核。随后，使用修正线性单元（ReLU）激活函数 $\max(0, x)$ 处理卷积响应。

非线性映射层（Non-linear mapping layer） 通过映射操作，将每个 n_1 维特征向量转换为 n_2 维特征向量，从而生成 HR 图像块的特征图集合。这个过程可以视为使用 n_2 个尺寸为 1×1 的小卷积核。该层的操作定义如下：

$$F_2(Y) = \max(0, W_2 * F_1(Y) + B_2),$$

其中 W_2 包含 n_2 个卷积核，每个卷积核尺寸为 $n_1 \times f_2 \times f_2$ ， B_2 是 n_2 维的偏置项。

重建层（Reconstruction layer） 通过将 HR 图像块组合，重建出完整的 HR 图像，尽可能接近真实高分辨率图像。该层定义为：

$$F(Y) = W_3 * F_2(Y) + B_3,$$

其中 W_3 是包含 c 个卷积核的权重矩阵，卷积核尺寸为 $n_2 \times f_3 \times f_3$ ， B_3 是 c 维的偏置项。




图 1: SRCNN 的结构示意图

3 核心研究

本文主要侧重于分析图像相似性指数，因此大多数结果都仅以表格和数据的形式呈现。具体的图像结果仅作参考，因为人眼难以量化图像之间的相似情况。附录中有一组图像示例。

3.1 使用 Richard-Lucy 方法对图像进行 SR

我们对每张图像进行了 50 次迭代。每次迭代后，基于 SSIM 和 SSSIM 指标进行评估。所有迭代完成后，保存具有最高 SSSIM 得分的中间图像作为最佳结果图像，用于后续项目阶段的数据处理。方法的结果总结如表2所示。

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.733	0.088	0.682	0.109
10.001	0.732	0.081	0.673	0.119
10.0015	0.596	0.092	0.517	0.129

表 2: Richard-Lucy 分数情况

通过分析结果，可以看出所有数据集在图像相似性方面均有显著提升。

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	30.01	22.83	2.99	7.00
10.001	32.61	22.81	2.53	8.72
10.0015	48.29	5.81	1.28	4.42

表 3: 达到最佳分数所需的迭代次数情况

由上表可知，不同数据集在 SSSIM 指标下，不超过 10 次迭代就能够达到最佳值。所以，对于 SSSIM 指标而言，所有数据集均设置 50 次迭代产生的结果是有说服力的。而对于 SSIM 指标，“迭代 50 次”这一设置把一些可能的最佳 epoch 值“拒之门外”，因为它们 MEAN+SD 都超过了 50。要想得到更加准确的最佳 epoch 情况，需要多次调整迭代次数来观察。

另外, 在 SSSIM 指标下平均最佳 epoch 远小于 SSIM 指标的, 这说明 Richard-Lucy 方法更侧重于修复图像的细节区域, 这使得在迭代过程中 SSSIM 分数增长更加迅速, 几次下来便可以达到最佳值。

3.2 使用 SRCNN 方法对图像进行 SR

为了评估 SRCNN 方法的稳定性, 我们设计了一个稳定性方案。该方案的核心目的是量化模型结果的变异性, 并为研究者提供结果稳定性的度量。为实现这一目标, 首先对预处理后的数据进行 5 折交叉验证 (5-fold Cross-Validation, CV), 从而生成五个不同的数据集。每个 5 折数据集由四折组成的训练集和一折组成的测试集构成。

随后, 在每个 5 折数据集的训练集中, 进一步进行 10 折交叉验证, 生成每个原始数据集对应的 10 个新的数据子集。每个 10 折数据子集由 9 折作为训练集, 剩余 1 折作为验证集。

在此基础上, 针对每个新的数据子集, 执行以下流程:

1. 使用训练数据进行模型训练, 训练若干轮。本文设置轮数 $epoch = 5$ 。
2. 在每个 epoch 结束后, 使用验证集评估模型性能, 评估指标包括 SSIM 和 SSSIM。
3. 根据在验证集上获得最高 SSSIM 分数的 epoch, 确定最佳 epoch。
4. 将最佳模型在对应的保留测试集上进行测试, 评估指标同样包括 SSIM 和 SSSIM。
5. 对每个 10 折数据子集, 重复步骤 1 至 4。
6. 对每个 5 折数据集, 重复步骤 1 至 5。

该方案的整体流程亦如图2所示。

对于特定的数据集和特定的 SRCNN 网络设置, 完整一轮测试完毕后, 我们会得到五个测试集 (五折交叉验证, 5-fold), 每个测试集的数据量是总共图片数据量 (本文为 474) 的 $1/5$ 。我们把所有结果整合在一起统计分析。这样避免了单一测试集偶然因素的影响, 统计意义更强、更有说服力, 而且也更简洁。

我们使用不同的损失函数设计准则, 进行了如下实验。

3.2.1 MSE 准则

论文 [4] 中的 SRCNN 算法, 使用的损失函数准则是 MSE。本文先使用这一 MSE 准则, 对三个数据集进行超分辨率还原, 并分析参数。得到表4结果:

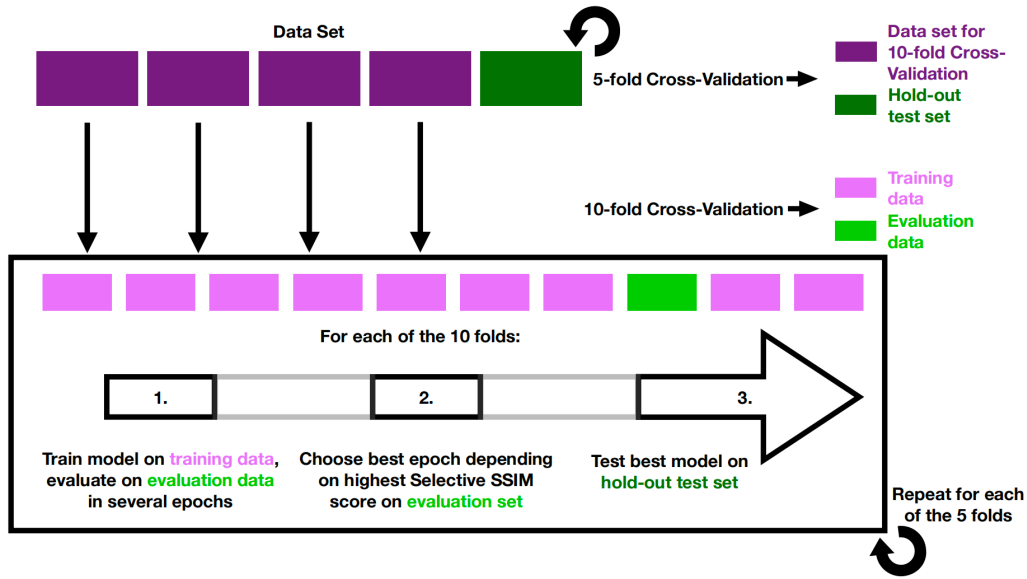


图 2: 完整稳定性方案流程图

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.983	0.027	0.791	0.230
10.001	0.982	0.029	0.882	0.214
10.0015	0.982	0.027	0.900	0.191

表 4: SRCNN (使用 MSE 准则的损失函数) 结果

可以观察到：在 SSIM 指标上，三个数据集的平均值基本相同，并且已经非常接近满分。但在 SSSIM 指标上，数据集 4.001，10.001，10.0015 降质幅度依次升高，然而呈现出更高的均值和更低的标准差，说明重建细节区域的效果和稳定性反而更好。其中，从数据集 4.001 到 10.001 我们增加的是模糊，从数据集 10.001 到 10.0015 我们增加的是噪声，从相应的增加幅度可以看出，模糊相比于噪声更加影响 SRCNN 效果。

我们猜测，更显著的降质变化反而更容易被 SRCNN 捕捉和学习，最终给出更优秀的结果。

3.2.2 加权 MSE 准则

我们修改损失函数准则为加权 MSE，使得中心区域相比于边缘区域对应更高权重，这样 SRCNN 在学习时会更加注重中心细节部分的恢复。在代码部分，将

```
criterion = nn.MSELoss()
```

替换为

`criterion = CenterWeightedMSELoss(alpha=ALPHA)`。

对于图像上面某个像素，所对应的权重与它距离中心点的距离呈负线性相关的关系；正中心的像素对应权重 $1 + \alpha$ ，边界上的像素对应权重 1。我们多次调整 α 值，观察结果，发现设置 $\alpha = 2$ 能得到比较好的结果，既对中心区域有所侧重，又不完全忽视边缘区域。表5是对应结果：

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.985	0.027	0.792	0.230
10.001	0.984	0.031	0.886	0.208
10.0015	0.979	0.028	0.901	0.177

表 5: SRCNN（使用加权 MSE 准则的损失函数， $\alpha = 2$ ）结果

我们发现，使用加权 MSE 的提升效果比较有限——MEAN 有小幅增长，同时保持 SD 不增加。但即使效果提升不大，改进是稳健的、全局一致的。尤其是对于数据集 10.0015，SSSIM 分数均值已经超过了 0.9，比较接近饱和，要想进一步提升，需要投入非常多的计算资源，性价比不高。

3.2.3 MAE 准则

MSE 适合整体优化，但容易平滑细节，因为它过于侧重对少数高误差区域的拟合；而 MAE（Mean Absolute Error）更适合天文图像恢复中细节结构的一致性，不会让少数极端像素（比如亮星、坏点）主导训练过程。

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.989	0.032	0.766	0.273
10.001	0.989	0.033	0.919	0.155
10.0015	0.989	0.032	0.939	0.147

表 6: SRCNN（使用 MAE 准则的损失函数）结果




图 3: MAE, 不同数据集 SSIM/SSSIM 分数的柱状图

由表6可知，相较于 MSE 准则的结果，MAE 在 SSIM 指标下对三个数据集均有微小的提升。而在 SSSIM 指标下，三个数据集均有可观的变化（大约为 3 个百分点），其中数据集 4.001 对应分数下降，而数据集 10.001 和 10.0015 对应分数则上升。这说明 MAE 准则确实更加匹配 SSSIM 指标，对细节区域关注度更高。而数据集 4.001 对应分数反而下降的原因，是它相较于另外两个数据集，本身降质幅度不大，可能产生“过拟合”现象——所设置的加权损失函数过于侧重中心区域，而实际数据集中心相比于边缘并没有太大差别，使得模型在训练集上所得到的参数用于测试集时效果并不理想。

3.2.4 加权 MAE 准则

类似于 MSE 到加权 MSE 的设计，将 MAE 修改加权 MAE，得到7结果：

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.989	0.031	0.771	0.243
10.001	0.988	0.032	0.944	0.134
10.0015	0.989	0.033	0.946	0.113

表 7: SRCNN（使用加权 MAE 准则的损失函数， $\alpha = 2$ ）结果

加权之后 SSSIM 指数相较于不加权的 MAE 进一步提高，而且提高幅度明显大于 MSE 的加权改进。类似的数据变化表现，进一步证实了“加权 MSE 准则”一节中提到的，加权损失函数的效果与稳定性。

3.2.5 更大的加权幅度

为了进一步探索加权损失函数的影响，我们调整权重至 $\alpha = 4$ ，得到表8和表9结果。

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.986	0.027	0.797	0.224
10.001	0.982	0.029	0.882	0.221
10.0015	0.981	0.027	0.904	0.183

表 8: SRCNN (使用加权 MSE 准则的损失函数, $\alpha = 4$) 结果

数据集	SSIM		SSSIM	
	MEAN	SD	MEAN	SD
4.001	0.989	0.032	0.778	0.239
10.001	0.989	0.032	0.940	0.151
10.0015	0.988	0.032	0.925	0.124

表 9: SRCNN (使用加权 MAE 准则的损失函数, $\alpha = 4$) 结果

3.2.6 总结

我们把所有结果汇总如表A.1, 设置数据集作为一级行标题, 损失函数准则作为二级行标题, 这样可以侧重于分析对于同一个数据集, 不同的损失函数准则产生的 SRCNN 恢复效果及稳定性。我们综合分析汇总结果, 可以得出以下结论:

- 在 SSIM 指标下, 不论数据集还是损失函数准则, 所有得分结果非常接近, 表明损失函数设计对整体图像质量的影响较小。
- 对于 SSSIM 指标, MEAN 的提升同时往往也对应 SD 的下降 (或者保持不变), 说明效果和稳定性的提升是同时性的。但也有例外。
- 对于 SSSIM 指标, 选择 MAE 还是 MSE 作为准则的影响大于是否使用加权因子; 而在数据集 10.001 和 10.0015 上, MAE 准则甚至超过了加权 MSE 的效果。
- 在相同的 MAE/MSE 准则下, 加权损失函数的效果普遍优于不加权的。

4 结论

本文围绕天文图像超分辨率重建问题，基于 Richard-Lucy 方法以及 SRCNN 模型框架，系统研究了不同低分辨率数据集下的图像恢复性能，并提出了加权损失函数设计以增强细节区域重建效果。主要结论如下：

- SRCNN 方法结果普遍显著优于 Richard-Lucy 方法，可见深度学习为图像超分辨率带来了突破性进展。其中 SSIM 接近满分，而 SSSIM 仍有提升空间。
- SRCNN 方法结果与初始图像质量没有很明显的正向关系，在我们的实验中，数据集 10.0015 的降质幅度最大，但进入 SRCNN 网络之后输出的 SR 图像反而评分最高。我们猜测，在更大尺度模糊和噪声背景下，SRCNN 更易于学习到这些特征，给出更优秀的结果。
- 本文的核心，是设计了基于中心加权的损失函数，包括加权 MSE 和加权 MAE。在引入加权机制后，在各个数据集上 SSSIM 进一步提升，重建效果更加稳定，验证了加权策略对于中心细节区域恢复的有效性。
- 对于特定的数据集，使用 MSE 还是 MAE 准则，是否应该加权，加权幅度如何，没有统一的定论，需要多次进行实验，得出最佳结果。另外，SSIM 和 SSSIM 分数都只是量化指标，不能完全反映人眼对于具体图像感知的复杂情形。

综上，本研究验证了加权损失函数在天文图像超分辨率重建中的应用潜力，尤其在提升细节结构一致性（SSSIM）方面具有积极作用，为后续进一步优化超分辨率网络的结构感知恢复性能提供了有效参考。

未来工作可以考虑引入动态可学习的权重生成机制，结合结构敏感型损失（如基于 SSIM 或 VIF 的感知损失）[2]，进一步提升细节区域的恢复效果。同时，扩展到更多实际天文观测数据的测试与分析，将更全面验证本方法在真实复杂环境下的适应性与泛化能力。


一些具体的改进和提升建议：1. 对于不同的图像，自动调整加权损失函数参数。先初始化参数，进行若干次学习，然后不断调整参数。调整到合适的参数后，再进行训练来生成结果；2. 相比于线性加权，可以采用其他更精细、更灵活的加权策略；3. SRCNN 网络的设计需要紧密参考图像相似性评估方法（如 SSIM 和 SSSIM）。在训练过程中，损失函数往往不断减小，但图像评价分数并不一定同步升高。我们可以探索一种机制，能让损失函数乃至整个网络的设计更加配合图像评价分数的需要。

参考文献


- [1] Chao Dong, Chen Change Loy, Kaiming He, and Xiaoou Tang. Image super-resolution using deep convolutional networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(2):295–307, February 2016.
- [2] Arash Chaichi Mellatshahi and Shohreh Kasaei. Trainable loss weights in super-resolution. *arXiv preprint arXiv:2301.10575*, 2023. <https://doi.org/10.48550/arXiv.2301.10575>.
- [3] Fionn Murtagh, Jean-Luc Starck, and Eric Pantin. Deconvolution in astronomy: A review. *Publications of the Astronomical Society of the Pacific*, 114(800):1090–1104, October 2002.
- [4] Julia Netzel. Statistical stability of super-resolution for astronomical imaging. Master thesis, ETH Zürich, Department of Mathematics, September 2023.
- [5] Zhou Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, 2004.

附录

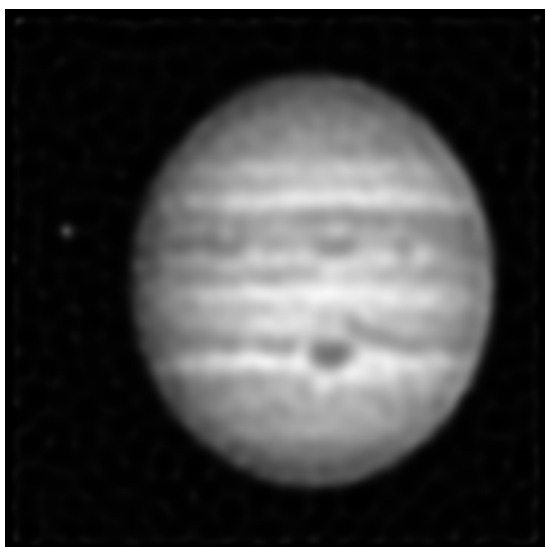
本文相关代码: <https://github.com/CheeseLee888/AstronomyImageSR.git>




(a) HR 图像



(b) LR 图像



(c) Richard-Lucy 重建图像



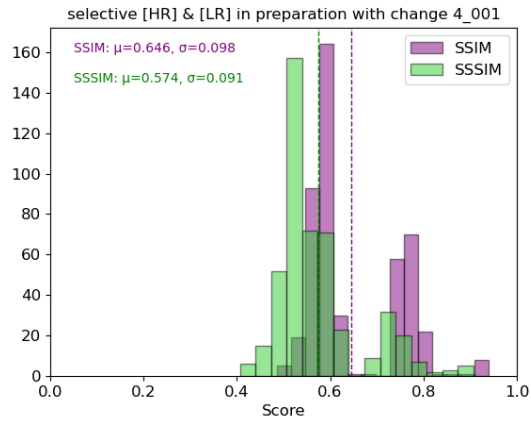
(d) SRCNN(MSE) 重建图像

图 A.1: 数据集 4.001 中的木星图像情况


本文相关图表：

数据集	损失函数	SSIM		SSSIM	
		MEAN	SD	MEAN	SD
4.001	MSE	0.983	0.027	0.791	0.230
	加权 MSE ($\alpha = 2$)	0.985	0.027	0.792	0.230
	加权 MSE ($\alpha = 4$)	0.986	0.027	0.797	0.224
	MAE	0.989	0.032	0.766	0.273
	加权 MAE ($\alpha = 2$)	0.989	0.031	0.771	0.243
	加权 MAE ($\alpha = 4$)	0.989	0.032	0.778	0.239
10.001	MSE	0.982	0.029	0.882	0.214
	加权 MSE ($\alpha = 2$)	0.984	0.031	0.886	0.208
	加权 MSE ($\alpha = 4$)	0.982	0.029	0.882	0.221
	MAE	0.989	0.033	0.919	0.155
	加权 MAE ($\alpha = 2$)	0.988	0.032	0.944	0.134
	加权 MAE ($\alpha = 4$)	0.989	0.032	0.940	0.151
10.0015	MSE	0.982	0.027	0.900	0.191
	加权 MSE ($\alpha = 2$)	0.979	0.028	0.901	0.177
	加权 MSE ($\alpha = 4$)	0.981	0.027	0.904	0.183
	MAE	0.989	0.032	0.939	0.147
	加权 MAE ($\alpha = 2$)	0.989	0.033	0.946	0.113
	加权 MAE ($\alpha = 4$)	0.988	0.032	0.925	0.124

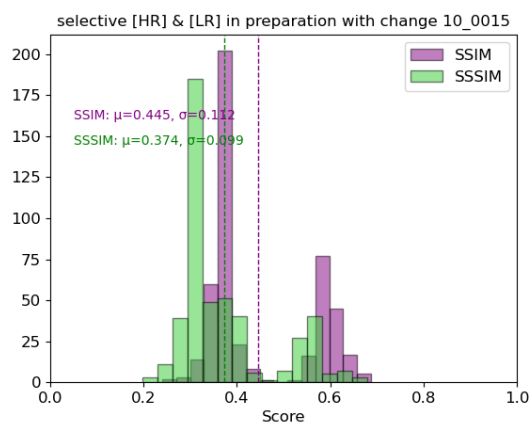
表 A.1: SRCNN 模型在不同数据集与不同损失函数设置下的 SSIM/SSSIM 分数汇总结果



(a) 数据集 4.001

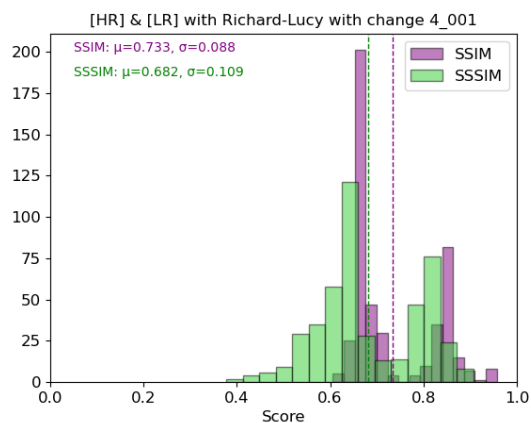


(b) 数据集 10.001




(c) 数据集 10.0015

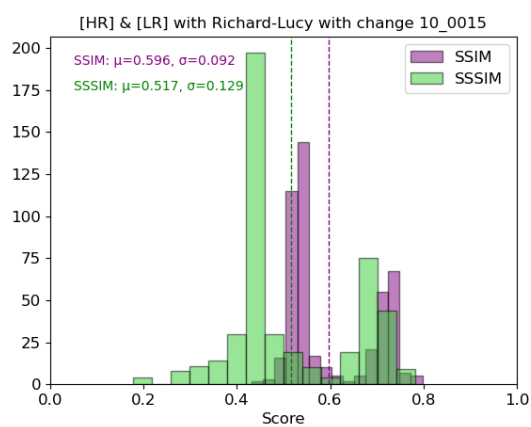
图 A.2: 准备阶段的 SSIM/SSSIM 分数柱状图



(a) 数据集 4.001




(b) 数据集 10.001




(c) 数据集 10.0015


图 A.3: 使用 Richardson-Lucy 方法后的 SSIM/SSSIM 分数柱状图




(a) MSE (无加权)



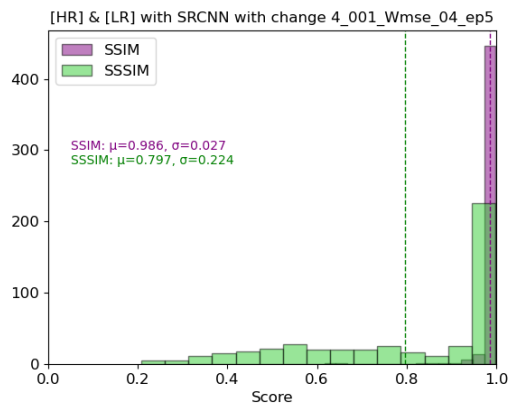
(b) MAE (无加权)




(c) MSE 加权 $\alpha = 0.2$



(d) MAE 加权 $\alpha = 0.2$




(e) MSE 加权 $\alpha = 0.4$




(f) MAE 加权 $\alpha = 0.4$


图 A.4: 不同损失函数与加权参数下, 数据集 4.001 使用 SRCNN 后的 SSIM/SSSIM 分数柱状图




(a) MSE (无加权)




(b) MAE (无加权)




(c) MSE 加权 $\alpha = 0.2$



(d) MAE 加权 $\alpha = 0.2$




(e) MSE 加权 $\alpha = 0.4$




(f) MAE 加权 $\alpha = 0.4$


图 A.5: 不同损失函数与加权参数下, 数据集 10.001 使用 SRCNN 后的 SSIM/SSSIM 分数柱状图




(a) MSE (无加权)




(b) MAE (无加权)




(c) MSE 加权 $\alpha = 0.2$



(d) MAE 加权 $\alpha = 0.2$



(e) MSE 加权 $\alpha = 0.4$



(f) MAE 加权 $\alpha = 0.4$

图 A.6: 不同损失函数与加权参数下, 数据集 10.0015 使用 SRCNN 后的 SSIM/SSSIM 分数柱状图